

학습 과학(Learning Sciences) 관점에서 본 3편의 논문 분석

AI는 왜 착각을 만드는가

메타인지 보정 · 인지부하 · 바람직한 어려움으로 읽는 생성형 AI

3조: 김혜진(교육공학) · 유나연(조기영어교육) · 조아리(AI융합교육) · 황지원(수학교육)

앞 팀 발표와 연결

공통점

Bastani et al. (2025, PNAS) 공통 분석
"수행 ≠ 학습", 가드레일의 중요성을 두 팀 모두 확인

메타인지적 착각 · 인지부하 · 교사 역할
외재적/본유적 부하, 교사는 가드레일 설계자

범용 AI → 교육용 AI 전환 필요성
두 팀 모두 교육용 AI의 필요성을 공통 제기

차이점 — 우리 팀의 초점

앞 팀: 4편 논문으로 넓게 탐색
소크라테스식 대화, 프롬프트 리터러시까지 확장

우리 팀: 3편으로 "보정(Calibration)"에 집중
과신이 왜 문제 → AI가 어떻게 악화 → 어떤 설계가 해결

독자적 기여: 3편 종합 + 수업 개념 적용 설계안
앞 팀이 다루지 않는 Chen & Alibakhshi (2026)

수행 ≠ 학습 → 왜 착각하는가 → AI가 어떻게 악화하는가 → 어떤 설계가 해결하는가

말하고자 하는 핵심 주제

"자신감도 AI도 그 자체로 중립이다. 학습자가 스스로 산출하고 점검하는
메타인지 루프를 지키느냐가 전부다."

인지적 구두쇠

뇌는 최대한 일을 안 하려 한다.
착각은 누구에게나 일어나기 쉽다.
'안다는 믿음'이 학습 행동을 결정.

과신이 학습을 멈춘다

초기 개입

사후 피드백은 늦다.
학습 시작 단계에서 개입해야 한다.
AI가 '착각 교정자' 역할을 해야.

AI가 착각을 심화한다

반복 인출

'산출 → 점검' 루프를 반복 보존.
반복 퀴즈로 착각을 깨고
자기평가를 계속 교정.

설계가 결과를 가르친다

승패는 도구가 아니라 '학습 설계(Learning Design)'에 달려 있다.

전체 개요 — 세 논문의 구성과 흐름

PAPER 1 · 문제 인식

메타인지 보정 불일치와 학습 전략의 관계

Lee & Bosch (2025)
Int. J. of AI in Education

- 과신이 학습 전략을 억제
- "믿음이 행동을 결정한다"
- 대학생 210명

PAPER 2 · 위험 증거

가드레일 없는 생성형 AI가 학습에 미치는 영향

Bastani et al. (2025)
PNAS

- 수행 ≠ 학습
- AI 차단 시 성적 -17%
- 고교생 ~1,000명

PAPER 3 · 해결책

AI 기반 메타인지 비계(Scaffold) 설계

Chen & Alibakhshi (2026)
JCAL

- Draft-first → AI Critique
- 전략 12~15% 향상
- 대학생 310명

1 과신이 전략을 억제 → 2 AI가 착각을 악화 → 3 설계로 해결

문제 인식

01

과신은 어떻게 학습을 멈추는가

Lee, H. & Bosch, N. (2025)

International Journal of Artificial Intelligence in Education, 35, 3746–3779

핵심 질문

"과신(overconfidence)은 학습 전략 사용을 어떻게 억제하는가?"

메타인지

보정 불일치

자기조절학습(SRL)

인지적 구두쇠

대학생 210명

인지적 구두쇠: 뇌는 왜 착각에 빠지기 쉬운가

메타인지란?

'생각에 대한 생각' — 무엇을 알고 모르는지 점검·조절하는 능력. 자기조절학습(SRL)의 핵심 요소

인지적 구두쇠 (Cognitive Miser)

뇌는 최대한 에너지를 절약하려 한다. 쉽게 처리되는 정보를 '아는 것'으로 착각 → 부호화 유창성(Encoding Fluency)

메타인지적 보정 (Calibration)

'자기 실력을 얼마나 정확하게 아는지'의 정도. 과신(Overconfidence) ↔ 과소확신(Underconfidence)

보정 개입의 한계

대부분 시험 후 '예상-실제 점수 차이'만 통보 → 왜 틀렸고 어떤 영향을 주는지까지 알려주는 초기 개입이 필요

부호화 유창성

인지적 구두쇠

처리 수준 이론

메타인지 점검·통제

'성적'이 아닌 '자신감'이 전략을 결정한다

연구 개요 미국 대학생 210명, 컴퓨터 기반 통계 학습 환경에서 학습 전 자기평가·실제 수행·학습 전략 분석

1 학생을 움직이는 것은 성적이 아니라 자기 확신이다
실제 점수보다 '안다'는 믿음이 행동을 결정 $b = -9.841, p < .001$

2 과신은 메타인지 전략 사용을 감소시킨다
과신할수록 준비·자기점검이 줄어들어 → 인지적 구두쇠의 발현

3 반복 퀴즈는 착각을 깨는 가장 효과적인 장치다
오답 피드백으로 현실적 자기평가 형성 → 인출 연습(Retrieval Practice)·시험 효과(Testing Effect)

4 사후 피드백은 늦다 — 초기 개입이 핵심
학습 종료 후가 아니라 '시작 단계'에서 개입 → 시험의 전방효과(Forward Effect)

5 AI는 '점수 제공자'가 아니라 '착각 교정자'여야
과신을 탐지하고 메타인지 전략을 추천하는 설계 필요

인출 연습

시험 효과

시험의 전방효과

초기 개입

인지적 구두쇠

과신 → 전략 억제 → 초기 개입과 반복 퀴즈가 답

논문 핵심

과신(overconfidence)이 메타인지 전략 사용을 억제한다.

'성적'이 아니라 '자신감'이 학습 행동을 결정한다.

수업 개념 연결

인지적 구두쇠 → 부호화 유창성 → 메타인지적 착각

인출 연습 · 시험 효과 · 시험의 전방효과 → 반복 퀴즈의 이론적 근거

다음 논문으로의 질문

이렇게 과신에 빠지기 쉬운 학습자가,

'정답'을 즉시 제공하는 생성형 AI를 자유롭게 쓰게 된다면?

시사점: 효과적 학습을 위해서는 자기 실력을 정확히 아는 것이 중요하며,
피드백 해석과 전략 선택을 학습 초기부터 안내하는 메타인지 지원 도구의 필요성을 시사한다.

과신한 학습자가 즉답 AI를 만나면?

학습 환경의 변화 자기 지식을 정확히 판단하기 어렵고 주관적 확신에 좌우되기 쉬운 학습자가, '정답'을 즉시 제공하는 생성형 AI를 자유롭게 쓰게 된다면?

1 보정 불일치(과신) 심화

AI의 완벽한 답변을 자신의 지식으로 착각
→ 유창성 환상 (부호화 유창성)

2 사고의 외주화 (Cognitive Offloading)

스스로 고민하고 오답을 고치는
바람직한 어려움(Desirable Difficulty)의
기회를 상실

3 인지적 게으름 고착화 (Metacognitive Laziness)

다 안다는 착각으로 공부 전
자기진단(메타인지 전략)을 생략
→ 생산적 실패(Productive Failure) 차단

인지부하 관점: AI는 외재적 부하(Extraneous Load)는 줄이지만, 깊은 처리를 만드는
본유적 부하(Germane Load)까지 줄여 '메타인지적 게으름'을 부른다.
→ 처리 수준 이론: 얕은 처리(AI 답변 복사)만 유발, 깊은 처리를 방해

바람직한 어려움

생산적 실패

인지적 외주화

처리 수준 이론

외재적/본유적 부하

위험 증거

02

수행은 올라가고, 학습은 무너지다

Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, Ö., & Mariman, R. (2025)
Proceedings of the National Academy of Sciences (PNAS), 122(26)

핵심 질문

"AI가 즉답을 제공하면 학습자의 수행(Performance)과 학습(Learning)은 어떻게 달라지는가?"

수행 ≠ 학습

가드레일

GPT Base vs Tutor

RCT

고교생 ~1,000명

GPT Base vs GPT Tutor — 설계가 만드는 차이

연구 개요 튀르키예 고교생 약 1,000명 대상 무작위 대조 실험(RCT). 수학 복습 세션에 GPT-4 기반 튜터 도입

① GPT Base

ChatGPT를 모방한 자유형
요청하면 정답을 그대로 제공

- 바람직한 어려움 제거
- 인지적 외주화 유발

연습 단계: +48% 수행

② GPT Tutor

가드레일 적용
정답 대신 단계별 힌트만 제공

- 생산적 실패 유지
- 자기설명 유도

연습 단계: +127% 수행

③ 통제군

AI 미사용

- 기존 학습 방식
- 비교 기준선

연습 단계: 기준선

이론적 통찰 연습 단계의 높은 '수행'이 곧 '학습'을 뜻하지는 않는다. **수행과 학습의 차이**

수행 vs 학습

바람직한 어려움

생산적 실패

자기설명

AI가 사라진 순간: 17% 성적 하락

-17%

AI 접근을 차단한 시험에서
GPT Base 집단이 통제군보다 낮은 성적

GPT Tutor는 통제군과 차이 없음
— 가드레일이 부정적 효과를 소멸

메커니즘 — 수행 ≠ 학습의 증거

GPT Base 첫 세션의 67%가
질문을 그대로 복사하거나 정답 요구

→ 얕은 처리(처리 수준 이론)
정답을 복사했을 뿐, AI 논리를 검증하지 않음

→ 잠재학습의 역방향
수행은 올라가지만 학습은 안 일어남

통제된 증거 같은 영역·같은 RCT 안에서 GPT Tutor(가드레일)는 부정 효과를 없앴다. '설계'가 결과를 가르친다는 직접 증거.

처리 수준 이론

잠재학습(역방향)

인출 연습 부재

인지적 외주화

양방향 착각: 메타인지 모니터링의 붕괴

환상 속의 학습자 (GPT Base)

시험 성적이 떨어졌는데도
자신이 덜 배웠다고 인식하지 못함

- 메타인지적 착각의 전형적 사례
- 부호화 유창성: AI의 매끄러운 답변이 착각 유발

반대 방향의 착각 (GPT Tutor)

시험 성적이 통제군과 다르지 않았는데도
자신이 더 잘했다고 인식

- AI를 쓰면 실제 학습 효과와 무관하게 "잘 배웠다"고 느끼는 착각이 양방향 발생

핵심 시사점 AI를 쓰면 실제 학습 효과와 무관하게 "잘 배웠다"고 느끼는 착각이 양방향으로 발생

- 메타인지 모니터링의 붕괴. GPT Base의 정답률은 51%에 불과 (논리 오류 42%, 산술 오류 8%)

현재 범용 AI는 오답도 확신에 차서 단정적으로 말함 → 학습자가 비판 없이 수용.

교육용 AI는 **확신도에 따라 어조를 조절**하는 설계가 가능.

메타인지적 착각

부호화 유창성

범용 AI vs 교육용 AI

가드레일 없는 AI → 착각 심화 → 설계가 결과를 가르다

논문 핵심

- 수행(Performance)과 학습(Learning)은 다르다.
- GPT Base는 -17% 하락, GPT Tutor는 부정 효과 소멸 → 설계의 힘.

수업 개념 연결

- 수행 vs 학습 · 처리 수준 이론 · 잠재학습
- 바람직한 어려움 · 생산적 실패 · 인지적 외주화

다음 논문으로의 질문

- 위험은 확인했다. 그렇다면
- AI를 '정답 도구'가 아닌 '메타인지 비계'로 어떻게 재설계할 것인가?

무너진 메타인지를 어떻게 복원할 것인가?

Paper 2의 증거 가드레일 없는 AI는 학습을 -17% 하락시켰다. 그러나 같은 실험에서 GPT Tutor(가드레일)는 부정 효과를 없었다. 관건은 AI 자체가 아니라 '설계'다.

1 발생효과 (Generation Effect)

학습자가 먼저 산출해야 한다.
AI가 대신 만들어주면
발생효과가 사라진다.

2 생산적 실패 (Productive Failure)

틀러보는 경험이 학습이다.
AI 즉답은 이 기회를
원천 차단한다.

3 바람직한 어려움 (Desirable Difficulty)

적절한 인지적 부담이
장기 기억과 전이를 강화.
AI가 대신 저서는 안 된다.

→ Paper 3은 이 세 원리를 보존하는 AI 설계를 실증한 연구다.

'Draft-first → AI Critique' 워크플로우로 산출·점검 루프를 복원한다.

발생효과

생산적 실패

바람직한 어려움

깊은 처리

자기설명

해결책

03

AI를 메타인지 비계로 재설계하다

Chen, J. & Alibakhshi, G. (2026)

Journal of Computer Assisted Learning, 42(1), e70171

핵심 질문

"AI를 '정답 도구'가 아닌 '메타인지 비계'로 설계하면 학습 전략과 성취가 달라지는가?"

Draft-first

AI Critique

발생효과

비계(Scaffold)

대학생 310명

Draft-first → AI Critique

연구 개요 대학 EFL 학습자 310명, 12주간 ChatGPT·Poe·Bard 활용. 학급 단위 준실험 — 인과 추론은 RCT보다 제한적.

Step 1 Draft-first

학생이 먼저 초안 작성

→ 발생효과(Generation Effect)

깊은 부호화 발생



Step 2 AI Critique

AI는 정답 X, 비판적 피드백 O

→ 바람직한 어려움 유지

자기설명(Self-explanation) 유도



Step 3 Human Eval

교사 평가 → 학생 수정 결정

→ 메타인지 루프 완성

모니터링·계획·평가 보존

- 두 축의 가드레일 6시간 AI 리터러시 워크숍 + 12주 Guided Practice(저널 기반 성찰)
- 학습과학적 의미: AI를 '사고를 비추는 거울(비계)'로 설계 — 학생이 먼저 산출, AI는 모니터링 지원

발생효과

자기설명

바람직한 어려움

메타인지 루프

AI 피드백의 구체적 예시

[논증 구조]

현재 글에 명확한 thesis statement가 없습니다. "I think it is good"은 너무 모호합니다. "어떤 측면에서" 좋은지 명시해 보세요.

[논리적 일관성]

반론을 언급했지만, 왜 그렇게 생각하는지 설명 없이 바로 반박했습니다. 반론을 공정하게 제시한 후 반박하면 논증이 더 강해집니다.

[근거의 구체성]

"Students can use internet to find information"은 너무 일반적입니다. 구체적인 예시나 데이터를 추가해 보세요.


[학술적 어조]

"very important", "learn more easily"는 구어적입니다. 학술적 표현(예: "plays a pivotal role")을 사용하세요.

→ AI가 정답을 주는 것이 아니라 사고의 부족한 부분을 지적 → 학습자 스스로 수정 결정.

자기설명(Self-explanation)과 메타인지 모니터링을 유발하는 핵심 메커니즘

AI 피드백 이후 학생의 사고 과정



- **보정 불일치와의 연결** Lee & Bosch(2025)의 "보정 불일치"와 직접 연결. AI 비평을 통해 과대평가를 교정 가능.
- **학습과학적 의미** "내가 뭘 모르는지" 인식(모니터링) → "어떻게 고칠지" 결정(계획) → "나아졌는지" 판단(평가) **이 세 가지가 메타인지 전략의 핵심**

→ 교수를 통한 학습(Learning by Teaching)과도 연결: AI에게 설명하는 과정 자체가 자기설명과 프로테제 효과를 유발

메타인지 점검·통제

자기설명

프로테제 효과

보정 불일치 교정

전략·성취 향상 — 바람직한 어려움이 보존된 설계의 증거

전략 사용 **12~15% 향상** (partial η^2 0.16~0.19)

언어 성취 **partial $\eta^2 = 0.22$**

분산 인지 (Distributed Cognition)

학생이 먼저 산출한 뒤 AI에 위임 → Bastani의 외주화와 달리 모니터링 루프 보존

자기효능감 — 보정된 자신감

오류 불안↓, '고칠 수 있다'는 통제감↑

실제 성취 향상을 동반한 '보정된 자신감' — Paper 1·2의 착각적 자신감과 구분

⚠ **해석 유의** Chen & Alibakhshi(2026)는 'AI 없이 본 전이시험'을 Bastani처럼 명시하지 않았고, 보정 정확도를 직접 측정하지도 않았다.

→ 전략·성취 향상을 본 준실험으로 해석하는 것이 정확.

바람직한 어려움

발생효과

분산 인지

자기효능감 vs 과신

세 키워드로 묶다 — 인지적 구두쇠 × 초기 개입 × 반복 인출

	Paper 1 Lee & Bosch	Paper 2 Bastani et al.	Paper 3 Chen & Alibakhshi
인지적 구두쇠	과신이 전략을 억제 부호화 유창성 → 착각	AI 즉답이 착각 심화 유창성 환상 → 외주화	Draft-first로 구두쇠 성향 극복
초기 개입	사후 피드백은 늦다 시작 단계에서 개입	GPT Tutor는 초기부터 힌트만 제공 → 효과	AI 리터러시 워크숍 6시간 사전 교육
반복 인출	반복 퀴즈가 착각을 깨는 가장 효과적 장치	GPT Tutor의 단계별 힌트 = 반복적 인출 유도	12주 Guided Practice 저널 기반 반복 성찰

세 키워드가 세 논문을 관통한다 — 문제 인식 → 위험 증거 → 설계로 해결

논문 간 방법론 비교와 증거 수준

Paper 1 Lee & Bosch (2025)

- 연구 설계: 상관 연구
- 대상: 대학생 210명
- 인과 추론: 제한적

강점: 부정 불일치와 전략의 직접 연결

한계: 실험 조작 없음

Paper 2 Bastani et al. (2025)

- 연구 설계: 무작위 대조 실험 (RCT)
- 대상: 고교생 ~1,000명
- 인과 추론: 강함

강점: GPT Base vs Tutor vs 통제군 비교

한계: 수학 단일 영역, 단기 개입

Paper 3 Chen & Alibakhshi (2026)

- 연구 설계: 준실험 (학급 배정)
- 대상: 대학생 310명, 12주
- 인과 추론: 제한적

강점: 전략·성취 향상 확인, 12주 장기

한계: AI 없이 본 전이시험 부재

증거의 수렴 Paper 2(RCT)는 가드레일 효과를 인과적으로 입증, Paper 3(준실험)은 다른 영역(작문)에서 교차 검증

→ 방법론은 다르지만 '산출·점검 루프 보존'이라는 공통 원리로 수렴

교육적 함의 ① 교수자 관점

AI는 양날의 검

- 무방비한 AI는 메타인지를 무너뜨리나(Paper 2),
- 가드레일과 함께라면 자기조절학습을 강화(Paper 3)

교수자 = 인지 환경 설계자

- '학습자의 인지적 개입을 어떻게 유지·강제할 것인가'를 설계.
- GPT Tutor처럼 바람직한 어려움을 유발하는 역할.

자기조절학습의 역설

- 자기조절 역량이 높은 학생일수록 AI가 오히려 방해될 수 있음.
- 학습 흐름 끊김 → 학생별 맞춤 개입 설계 필요.

발표 = 자연스러운 가드레일

- AI로 과제를 해도 발표하게 하면 자기 수준이 드러남.
→ 교수를 통한 학습(Learning by Teaching)·프로테제 효과 활용.

교수를 통한 학습

프로테제 효과

자기조절학습

바람직한 어려움

교육적 함의 ② 도구 활용 관점

범용 AI → 교육용 AI

- 현재 쓰는 건 모두 범용 AI. 교육용 AI는 확신도에 따라 어조를 조절 가능.
- 1인 1태블릿 세팅 시 가드레일 문제 해결 가능성.

비판적 프롬프트 리허설

- 학습자도 프롬프트 역량을 길러야 함.
- 맥락 + 비판 + 입출력 관계의 메타적 인식. 프롬프트 설계 자체가 메타인지 훈련.

마이크로 단위 설계 방안

- Draft-first: 학생이 먼저 산출 → 발생효과 보존
- AI Critique: 정답 대신 비판적 피드백 → 자기설명 유도
- 반복 퀴즈: 학습 초기부터 개입 → 인출 연습·시험의 전방효과
- 성찰 저널: 12주 지속 → 메타인지 루프 습관화

핵심 메시지 자신감도 시도 그 자체로 종립이다. **모니터링 루프를 지키느냐**가 선택을 가른다.

각자 선생님들이 느낀 교육적 함의

김혜진 (교육공학)

- 학습자가 주도적으로 지식을 구조화·인출할 수 있는 환경을 구축하는 것이 진정한 '파지와 전이'를 유도하는 교수자의 핵심 역할.

유나연 (조기영어교육)

- 스스로 안다고 생각하여도 옆 친구에게 설명하도록 가르치고, 메타인지적 질문으로 스스로 점검 유도. '학습에 바람직한 어려움'을 경험하게 하여 인지적 성장 유도.

조아리 (AI융합교육)

- AI를 '제 답변을 점검해주는 코치'로 활용. AI 사용의 성취감이 진짜 똑똑해짐인지 유창함의 함정인지 구분하기 어려워 스스로 경계함이 필요.

황지원 (수학교육)

- 우리도 가드레일 없이 AI를 쓰는 실수를 범할 수 있음. 소크라테스식 질문법 적용 LLM 사용법, 교수자의 동기 유발이 중요.

Q & A

참고문헌

- Lee, H., & Bosch, N. (2025). Calibration Discrepancy Predicts Students' Subsequent Metacognitive Strategy Use. *Int. J. of AI in Education*, 35, 3746–3779.
- Bastani, H., et al. (2025). Generative AI without guardrails can harm learning: Evidence from high school mathematics. *PNAS*, 122(26), e2422633122.
- Chen, J., & Alibakhshi, G. (2026). AI-Powered Applications' Effects on ELL's Strategies and Achievement. *JCAL*, 42(1), e70171.
- Learning Sciences 강의 자료